

AI-Driven Acceptance Testing: first insights exploring the educational potential for test analysts

Caio Jordan de Lima Maia
Universidade Federal da Paraíba
João Pessoa, Brasil
caiojdlmaia@gmail.com

Yuska Paola Costa Aguiar
Departamento de Informatica
Universidade Federal da Paraíba
João Pessoa, Paraíba, Brasil
yuska@ci.ufpb.br

Abstract

This article examines the potential of AI-based natural language processing models, such as ChatGPT and Bard, as educational tools in the context of acceptance test case creation. The principal findings indicate that test cases manually generated by two QA professionals (one junior and one senior) exhibited reduced coverage and accuracy in comparison to those generated by the AIs, which, while expeditious, also demonstrated limitations. The findings indicate that AI can significantly enhance the learning process for less experienced QA professionals by providing clear and structured examples. Furthermore, collaboration between AI tools and experienced professionals optimizes the process, offering greater efficiency and test coverage. The study underscores the importance of integrating technological advancements into educational practices to better prepare future software quality professionals.

CCS Concepts

• **Computing methodologies** → **Artificial intelligence**; • **Applied computing** → **Education**.

Keywords

Software Quality Education, Generative AI-Supported Education, Acceptance Test, Test Plan, Quality Assurance, ChatGPT, Bard

ACM Reference Format:

Caio Jordan de Lima Maia and Yuska Paola Costa Aguiar. 2024. AI-Driven Acceptance Testing: first insights exploring the educational potential for test analysts. In *XXIII Brazilian Symposium on Software Quality (SBQS 2024)*, November 05–08, 2024, Salvador, Brazil. ACM, New York, NY, USA, 8 pages. <https://doi.org/10.1145/3701625.3701691>

1 Introdução

A engenharia de software engloba uma ampla gama de atividades que abrangem todo o ciclo de produção de software, incluindo a especificação, desenvolvimento, validação e evolução do software [13]. A validação do software é uma etapa de extrema importância que perpassa todo o processo de desenvolvimento, com foco na garantia da qualidade do produto, dos envolvidos e do próprio processo em si. Um processo de desenvolvimento de alta qualidade desempenha

um papel crucial na redução de defeitos, no encurtamento de prazos e na entrega eficiente do software [10]. A realização de testes é uma prática vital ao longo de todo esse processo, e a incorporação de uma abordagem de gestão de qualidade desde as fases iniciais, como o planejamento, possibilita a identificação de problemas antes mesmo de sua concretização.

Na fase inicial do ciclo de desenvolvimento de software, a de levantamento de requisitos, também são delineados os testes de aceitação. Segundo a definição de Sommerville [13], o teste de aceitação é "um processo de teste de usuário no qual o objetivo é decidir se o software é bom o suficiente para ser implantado e usado". Por meio dele, é possível validar se o software se comporta conforme o esperado pelos usuários, de acordo com as entradas fornecidas.

A criação de casos de teste de aceitação assume um papel vital nesse processo de testes de software. Esses casos oferecem uma estrutura organizada para o que precisa ser testado, delineando os fluxos de execução dos testes e estabelecendo os resultados esperados. Além disso, contribuem para uma compreensão mais clara do sistema por parte da equipe de desenvolvimento.

A adoção de metodologias ágeis trouxe mudanças significativas na forma como os casos de teste são elaborados. Atualmente, muitos projetos optam pelo Desenvolvimento Guiado por Comportamento (BDD, do inglês *Behavior Driven Development*) [12], uma abordagem que se concentra na compreensão e especificação do comportamento desejado de um sistema antes mesmo da escrita de código. Essa abordagem envolve a colaboração entre desenvolvedores, testadores e partes interessadas, como os próprios usuários ou clientes, para criar cenários de teste descritos em linguagem natural, conhecidos como "especificações". Essas especificações descrevem o comportamento esperado do sistema em termos de entradas, saídas e interações considerando o fluxo principal, alternativos e de exceção.

No contexto atual, os testes de aceitação desempenham um papel fundamental na garantia de que o software atenda aos requisitos dos usuários e do sistema. É crucial que os profissionais de testes adquiram, o quanto antes, a habilidade de criar casos de teste eficazes. Essa habilidade não só garante a cobertura abrangente dos requisitos, mas também facilita a identificação precoce de problemas, aumentando a eficiência do processo de desenvolvimento. O aprendizado precoce da criação de casos de teste ajuda os analistas de teste a desenvolverem um entendimento profundo do sistema, aprimorando sua capacidade de identificar cenários críticos e potenciais pontos de falha.

Não é surpresa que, com o surgimento de ferramentas que fazem uso de Inteligência Artificial (IA), tenham surgido métodos para

Publication rights licensed to ACM. ACM acknowledges that this contribution was authored or co-authored by an employee, contractor or affiliate of a national government. As such, the Government retains a nonexclusive, royalty-free right to publish or reproduce this article, or to allow others to do so, for Government purposes only. Request permissions from owner/author(s).

SBQS 2024, November 05–08, 2024, Salvador, Brazil

© 2024 Copyright held by the owner/author(s). Publication rights licensed to ACM.

ACM ISBN 979-8-4007-1777-2/24/11

<https://doi.org/10.1145/3701625.3701691>

simplificar e acelerar o processo de desenvolvimento de software. Ferramentas como o ChatGPT (OpenAI, 2022) [9] e o Bard (Google, 2023) [5], despertam a curiosidade sobre como podem ter um impacto positivo na área de qualidade de software. Pesquisas como o uso do ChatGPT para geração de entradas para casos de teste que induzam falhas no código [8] ou até mesmo a geração de casos de teste e de código para automação dos testes [14] são alguns exemplos de como a IA está sendo utilizada no mercado de qualidade de software.

A experiência descrita neste artigo teve como objetivo avaliar a utilização de modelos de processamento de linguagem natural baseados em inteligência artificial como ferramentas de aprendizagem na criação de casos de teste, analisando se o processo de especificação será mais rápido e se pode cobrir mais cenários do que os identificados pelo analista de teste. A motivação por trás dessa análise é demonstrar que a IA pode servir como uma ferramenta de ensino de habilidades essenciais para os profissionais de teste, os ajudando a aumentar sua análise crítica sobre os requisitos, aumentando sua capacidade de identificar um maior número de cenários de teste significativos e, potencialmente, melhorar a qualidade do software.

Para se tornarem profissionais de teste bem-sucedidos, os estudantes precisam desenvolver várias habilidades essenciais. Entre elas estão a atenção aos detalhes, o pensamento crítico, a comunicação escrita eficaz, a organização e a adaptabilidade, conforme discutido por Dias Valle *et al.* [15]. Com essas habilidades em mente, comparamos casos de teste criados por estudantes de diferentes níveis de experiência no mercado com aqueles gerados pelo Bard e ChatGPT.

Após essa comparação inicial, os estudantes utilizaram as ferramentas de IA para auxiliar na criação de seus próprios casos de teste. Em seguida, solicitamos que os estudantes avaliassem se o uso da IA ajudou na identificação de cenários de teste que antes não consideravam e se aprenderam sobre casos críticos que não possuíam conhecimento prévio.

Com isso, esperamos mostrar como a utilização de IA pode ser uma ferramenta aliada no processo educacional, auxiliando futuros analistas de teste a desenvolverem uma base sólida para suas carreiras, especialmente ao capacitá-los no domínio de habilidades essenciais para o mercado.

2 Fundamentação Teórica

2.1 Testes de Aceitação

Conforme definido pelo ISTQB no *Syllabus* [1], nos testes de aceitação, os casos de teste são criados com base nos critérios de aceitação, servindo como exemplificações do funcionamento do software. Isso desempenha um papel fundamental na garantia de que a equipe implemente com precisão a história do usuário. Os casos de teste devem abranger todas as funcionalidades descritas na história do usuário, sem ultrapassá-las. No entanto, é importante observar que os critérios de aceitação podem detalhar certos aspectos específicos da história do usuário. Adicionalmente, é recomendável evitar que dois casos de teste descrevam as mesmas funcionalidades da história do usuário, garantindo assim uma cobertura abrangente [1].

2.2 Criação de Casos de Teste e sua Importância

A criação de casos de teste é um processo no qual definimos cenários que serão executados para verificar se um requisito do sistema funciona conforme esperado. Eles podem ter pré-condições, um passo-a-passo de como realizar o teste, e até pós condições para finalizar o caso, além disso ele também fornece entradas a serem utilizadas e saídas esperadas.

Com criação adequada destes casos podemos garantir a cobertura dos requisitos, uma documentação para as partes interessadas, que facilita a compreensão dos requisitos e dos comportamentos esperados, além de garantir um rastreio no caso de surgir algum “bug”, podendo facilitar a reprodução do teste. Com isso também é garantido um aumento de confiança nos testes pelas partes interessadas, já que demonstra que o sistema funciona conforme o esperado.

2.3 Padrão internacional ISO 29119-3

A ISO 29119-3 [7] fornece diretrizes gerais para planejar, projetar e executar casos de teste funcionais. Ele tem como benefício a consistência, já que fornece um padrão para a documentação, ele também é mais reduzido e claro de entender, além de reconhecido internacionalmente. O *template* contempla os seguintes elementos: identificador do caso de teste, descrição, pré-condição, passos do teste, resultados esperados. Apesar disso, o *template* também pode variar de acordo com o projeto ou organização, para se adaptar às necessidades específicas, sendo flexível. Um exemplo de um caso de teste utilizando o padrão pode ser visto na Tabela 1.

2.4 ChatGPT e Bard

Tanto o ChatGPT da OpenAI, quanto o Bard da Google são modelos de processamento de linguagem natural que viabilizam a criação de diálogos mediante o uso de *prompts*, gerando respostas de forma artificial. A partir deles, é possível atender a demandas por textos e informações [2, 3].

A principal distinção entre esses sistemas reside na fonte de dados que os alimenta. Enquanto o ChatGPT utiliza um banco de dados gerido pela própria OpenAI, o Bard se vale do Google como fonte para buscar informações [2]. É importante salientar que uma diferença crucial entre os dois é a atualização de seus dados. Enquanto a versão gratuita do ChatGPT dispõe de informações até janeiro de 2022, o Bard gratuito é regularmente atualizado e é capaz de acessar e processar informações em tempo real por meio do Google, o que o torna mais atualizado em comparação com o ChatGPT [5, 9].

2.5 Aplicação da IA no Contexto de Teste Software

A aplicação da Inteligência Artificial (IA) no contexto de teste de software representa uma área de pesquisa e desenvolvimento em crescimento dentro da engenharia de software [6]. A IA é uma disciplina que visa criar sistemas capazes de realizar tarefas que normalmente exigiriam inteligência humana, e seu uso no teste de software oferece oportunidades significativas para melhorar a eficiência e a eficácia dos processos de teste.

A IA tem desempenhado um papel cada vez mais significativo no campo de testes, com diversas aplicações emergentes, incluindo

Tabela 1: Padrão ISO dos casos de teste

CT 1. Listar Tarefas	
Objetivo: Validar a funcionalidade de listar tarefas	
Pré-Condição: Ter tarefas	
Passos	Resultado Esperado
1. Ir para tela de tarefas	Aparecerá uma lista de tarefas existentes
2. Clicar no botão de Listar Tarefas	

a automação da geração de testes, detecção de defeitos e criação de casos de teste [14, 16]. Essa área tem experimentado um desenvolvimento impulsionado por novas pesquisas e aplicações inovadoras. Por exemplo, no artigo de Xie et al. [16] é demonstrado como o ChatGPT pode ser empregado de forma eficaz na geração automatizada de testes unitários. Porém não foi possível encontrar pesquisas mostrando se essas ferramentas seriam úteis na geração de casos de teste de aceitação, de forma que mantivesse a qualidade e a cobertura dos testes.

2.6 Aplicação da IA na Educação

A aplicação da IA na educação tem sido amplamente estudada em diversos artigos, abrangendo desde a personalização do ensino até a criação de sistemas de avaliação mais eficientes. A análise de dados e a aplicação de algoritmos permitem identificar áreas de desafio e progresso dos alunos, ajustando o ritmo de ensino às suas necessidades. Dessa forma, proporciona-se uma experiência de aprendizagem individualizada e eficiente, resultando na melhoria do desempenho educacional [4].

Conforme a revisão de Ramos da Silva et al. [11], o uso da IA na educação tem um impacto profundo. A IA permite uma personalização da aprendizagem, que melhora a eficácia do ensino, adaptando-se às necessidades individuais dos alunos e oferecendo suporte direcionado. Além disso, a tecnologia facilitou o acesso à informação e promoveu a independência dos alunos, embora também tenha limitado a abordagem integradora e a profundidade da análise crítica. Esta tecnologia, que evoluiu desde as primeiras ferramentas educacionais como vídeos e apresentações em PowerPoint, continua a transformar a forma como se ensina e aprende.

Na área de teste de software, a IA poderia auxiliar os alunos a entenderem os riscos de uma aplicação e as falhas mais comuns, orientando-os a realizar testes de forma eficaz. Com o uso de IA, os alunos poderiam também aprender a identificar áreas críticas do sistema que exigem maior atenção, o que facilita a priorização dos testes com base em dados reais e históricos de falhas. Além disso, a IA pode automatizar parte do processo de organização dos casos de teste, garantindo uma cobertura mais ampla dos cenários possíveis.

3 Trabalhos Relacionados

Para entender o contexto e a relevância dos testes de aceitação feitos por IA e seu potencial uso educativo para analistas de teste, consultamos, de forma exploratória, artigos retornados a partir de busca utilizando palavras-chave no GoogleScholar como "AI-driven acceptance testing", "educational potential", "test analysts", "machine learning in software testing", e "automated test case generation" priorizando resultados mais recentes (até 2024), considerando que

tanto o ChatGPT (2022) [9] quanto o Bard (2023) [5] são ferramentas relativamente novas. A seguir, apresentamos na Tabela 2 os estudos considerados relevantes, destacando suas contribuições e conclusões.

Como é possível ver na Tabela 2, apesar de não se concentrarem especificamente em testes de aceitação, os estudos analisados mostram que foram feitos diversos estudos tanto das possibilidades do uso da inteligência artificial na área de qualidade de software, quanto do seu uso para a formação de pessoas que atuam na área de Garantia da Qualidade (*Quality Assurance*). No entanto, ainda há uma lacuna significativa na literatura quanto à exploração específica do potencial educacional dos testes de aceitação realizados por IA para analistas de teste. Este artigo, busca preencher essa lacuna ao investigar como a aplicação de IA nos testes de aceitação pode oferecer valiosas oportunidades de aprendizado e desenvolvimento de habilidades para os analistas de teste em processo de formação.

4 Procedimentos Metodológicos

A metodologia foi conduzida com a participação de duas pessoas, ambas estudantes e com atuação no mercado enquanto analista de teste, com experiências distintas, menos de um ano, e mais de quatro anos - analistas Júnior e Sênior, respectivamente. Ambos os participantes assinaram um termo de consentimento e livre esclarecimento, garantindo que estavam plenamente cientes dos objetivos da pesquisa e de como seus dados seriam utilizados apenas de forma anônima.

Para o estudo foi utilizada a seguinte descrição de um requisito: "Como uma loja virtual, eu devo ter a funcionalidade de colocar, retirar ou finalizar compras no meu carrinho, lembrando que não posso finalizar um carrinho vazio e ao adicionar um mesmo produto ao carrinho não deve haver duplicações de produtos, será adicionado à sua quantidade no carrinho". Para sua execução, a metodologia aplicada consistiu no conjunto das seguintes etapas:

(i) solicitar as duas pessoas a criação de casos de teste para um requisito funcional utilizando o padrão estabelecido pela ISO 29119-3 [7] havendo sido fornecido um *template* para preenchimento do título do teste, passos, objetivo e resultado esperado;

(ii) realizar um segundo ciclo de levantamento de casos de teste, mas desta vez utilizando dois modelos de linguagem natural baseados em inteligência artificial: o ChatGPT e o Bard (usando as versões gratuitas de dezembro de 2023), utilizando como entrada o seguinte *prompt*: "Crie casos de teste funcionais de acordo com o ISO-29119-3 para a seguinte funcionalidade: Como uma loja virtual, eu devo ter a funcionalidade de colocar, retirar ou finalizar compras no meu carrinho, lembrando que não posso finalizar um carrinho vazio e ao adicionar um mesmo produto ao carrinho não deve haver duplicações de produtos, será adicionado à sua quantidade no carrinho".

Tabela 2: Trabalhos Relacionados

Ano	Título	Objetivos
2021	Role of Artificial intelligence in Software Quality Assurance	O trabalho destaca que a Inteligência Artificial (IA) está se tornando essencial na indústria de testes de software, prometendo melhorar os resultados e aumentar a precisão em um curto período, apesar de não ser muito utilizada devido ao desconhecimento das ferramentas por parte dos analistas de teste.
2016	Inteligência Artificial na Verificação e Teste de Software para Desenvolvimento Ágil	Propõe uma abordagem para automatizar testes de regressão em desenvolvimento ágil usando inteligência artificial. Enfatiza a importância dos testes de regressão em metodologias ágeis.
2023	Automatic code generation from behavior-driven development tests using machine learning: a vision	Explora a geração automática de código a partir de testes de desenvolvimento orientado por comportamento (BDD) usando aprendizado de máquina. Discute a importância da qualidade e cobertura dos testes.

Realizar 3 gerações para cada modelo, sendo que cada geração consistiu em uma nova tentativa de geração, usando a opção de re-geração do respectivo modelo, dos casos de teste. O propósito dessas três iterações foi selecionar a geração que melhor atendesse ao padrão pré-definido dos casos de teste, sendo selecionada pelo pesquisador, e a limitação de três gerações foi estabelecida como uma forma de equilibrar a exploração da capacidade dos modelos com a necessidade de manter o processo gerenciável dentro do escopo do estudo exploratório;

(iii) o pesquisador irá realizar a análise da estruturação dos casos, verificando se estão organizados de maneira lógica e clara, seguindo o padrão estabelecido;

(iv) o pesquisador irá realizar a comparação entre o gabarito dos casos de teste com os testes criados por humanos e os gerados pelo ChatGPT e Bard, verificando a quantidade de casos e a cobertura.

Durante esse processo, todos os participantes (incluindo o Bard e o ChatGPT), também terão o padrão estabelecido pelo ISO 29119-3, no qual é dado um formato específico para a geração dos casos de teste, para que assim seja possível avaliar melhor os casos gerados. Com isso, esse processo de comparação entre casos de teste elaborados por pessoas com diferentes níveis de experiência, bem como por modelos de IA, permitirá uma análise abrangente da qualidade dos casos gerados.

Vale ressaltar que todos os artefatos produzidos durante os procedimentos metodológicos, a principal resposta de cada modelo, e todos os casos de teste gerados pelos modelos de IA, bem como pelos analistas (Júnior e Sênior), estão disponíveis em um repositório público, o Figshare¹. Isso permitirá maior transparência no processo, facilitando a replicação futura dos experimentos e o aprofundamento de estudos.

Após essa fase inicial, os analistas foram instruídos a utilizar as ferramentas de IA para auxiliar na criação de seus próprios casos de teste durante um período determinado de 1 semana. Ao final desse período, solicitamos que os analistas avaliassem se o uso da IA ajudou na identificação de cenários de teste que antes não consideravam e se aprenderam sobre casos críticos que não possuíam conhecimento prévio. Buscando assim, demonstrar como a aplicação de IA no contexto educacional pode fornecer aos analistas de teste em formação novas perspectivas e abordagens, enriquecendo o aprendizado e incentivando o desenvolvimento de casos

de teste mais amplos e eficazes, além de aprimorar a compreensão das melhores práticas da área.

É importante ressaltar que este estudo é preliminar e exploratório, com limitações como o número reduzido de participantes (apenas dois analistas), o uso de apenas duas ferramentas de IA, o ChatGPT e o Bard, e com um único *prompt*. Seu propósito não é generalizar os resultados, mas sim experimentar a aplicabilidade da IA no contexto educacional. A motivação para essa análise exploratória surge da recente inclusão da disciplina de teste de software como componente obrigatório no segundo semestre do Curso de Ciência da Computação, do Centro de Informática da UFPB. Portanto, esta investigação inicial é um passo importante para futuras pesquisas mais abrangentes.

5 Análise dos Resultados

O relato descrito neste artigo teve como objetivo realizar um estudo exploratório da utilização de modelos de processamento de linguagem natural baseados em inteligência artificial como ferramentas para o aprendizado na criação de casos de teste de aceitação pelos profissionais de qualidade (analistas de teste). A intenção é facilitar o processo de aprendizado, melhorando as habilidades dos analistas e aumentar a cobertura de testes, abrangendo casos que poderiam ter passados despercebidos pelos testadores. Importante ressaltar que não foi passado nenhum limite ou quantidade mínima de casos a serem criados, sendo os mesmos responsáveis por decidir se os que foram criados já serviram para cobrir todos os cenários. Seguindo a metodologia descrita anteriormente temos os seguintes resultados:

Resultado do Levantamento Inicial de Casos de Teste (Etapa i): Ambos os testadores desenvolveram os casos de teste com as mesmas informações fornecidas e chegaram a uma quantidade idêntica de casos de teste. O analista de testes Júnior, um iniciante na área, levou aproximadamente 1 hora para elaborar 6 casos, conforme ilustrado na Tabela 3. Em contraste, o analista de testes Sênior, com mais experiência, precisou de 30 minutos para elaborar o mesmo número de casos de teste, como mostrado na Tabela 4.

Resultados da Utilização de Modelos de Linguagem Natural (Etapa ii): Na segunda etapa, empregamos os modelos de linguagem natural baseados em inteligência artificial, o ChatGPT e o Bard, para gerar casos de teste. As saídas desta etapa incluíram os casos de teste criados pelos modelos de IA, ChatGPT [Tabela 5] e Bard [Tabela 6].

¹Os artefatos da pesquisa estão disponíveis em: <https://doi.org/10.6084/m9.figshare.27074536.v1>

Tabela 3: Exemplo de Caso de Teste do Analista Júnior

3. Validar funcionalidade de remover produto do carrinho - produtos diferentes e em quantidade única	
Objetivo: Validar que a funcionalidade removerá do carrinho o(s) produto(s) desejado(s), mantendo os outros no carrinho	
Pré-Condição: Carrinho com produtos diferentes	
Passos	Resultado Esperado
1. Abro a página do carrinho	Que o usuário possa remover um ou mais produtos diferentes do carrinho de uma vez só
2. Seleciono a(s) checkbox(s) indicando quais produtos desejo selecionar	
3. Clico em "remover produto(s) do carrinho"	
4. Clico para confirmar remoção do(s) produto(s) do carrinho	

Tabela 4: Exemplo de Caso de Teste do Analista Sênior

5. Remover um produto do carrinho	
Objetivo: Validar que é possível remover um item do carrinho	
Pré-Condição: Carrinho vazio	
Passos	Resultado Esperado
1. Pesquisa um produto na barra de pesquisa	1. Deve ser exibido uma mensagem amigável perguntando se o usuário deseja realmente remover o item do carrinho e, após a remoção, deve ser exibido outra mensagem confirmando a remoção do produto.
2. Clico no produto escolhido	
3. Seleciono a quantidade desejada	2. Após os passos informados, o carrinho deve ser exibido sem nenhum produto (vazio)
4. Clico em "Adicionar ao Carrinho"	
5. Clico em "Carrinho"	
6. Removo o item adicionado nos passos anteriores do carrinho	

É igualmente crucial recordar que, em ambos os casos, realizou-se a geração de resultados em três repetições, selecionando aquele que melhor atendesse ao padrão predefinido dos casos de teste.

Análise da Estruturação dos Casos de Teste (Etapa iii): Tanto o Bard quanto o ChatGPT conseguiram desenvolver os casos de teste de forma que fosse possível compreender o funcionamento de cada teste, seguindo precisamente o padrão estabelecido pela ISO 29119-3. No entanto, é importante ressaltar que foi necessário realizar três iterações para que o ChatGPT conseguisse aderir ao padrão de geração de casos de teste, o qual abrange pré-condições, passos, objetivos e resultados esperados. Em contrapartida, o Bard demonstrou a capacidade de gerar os casos de teste de maneira correta logo na primeira iteração. Não obstante, ambos os modelos conseguiram estabelecer a estrutura adequada para a criação de casos de teste, seguindo o padrão e garantindo que os profissionais de garantia de qualidade possam compreendê-la com clareza.

Comparação dos Casos de Teste (Etapa iv): Na tabela a seguir [Tabela 8], apresentamos uma comparação dos casos de teste gerados por diferentes fontes, Gabarito, Analista Júnior, Analista Sênior, Bard e ChatGPT, com base na quantidade, avaliando se abrangem todos os cenários, incluindo a comparação com os cenários do gabarito [Figura 7]. Além disso, verificamos se os casos criados aderem às regras do requisito, tais como "finalizar carrinho com produto", "finalizar carrinho sem produto", "adicionar produto no carrinho", "retirar produto do carrinho" e "acrescentar quantidade de produto no carrinho". Também registramos o tempo gasto na criação desses casos de teste.

A partir da Tabela 8, fica evidente que o ChatGPT teve um desempenho satisfatório em termos de validação de regras do requisito e

tempo de criação de casos de teste, em comparação ao Analista de testes Júnior. Mesmo gerando um caso a menos, o ChatGPT conseguiu validar todas as regras do requisito proposto em menos de 1 minuto, em contraste com a uma hora gasta pelo Analista Júnior. Tanto o Bard quanto o Analista Júnior não conseguiram criar casos de teste que abarcassem todas as regras do requisito. No caso do Bard, não foi gerado um caso de teste que abrangesse a finalização do carrinho com um produto, enquanto o Analista Júnior não criou um caso de teste que validasse a finalização do carrinho vazio.

Além disso, é relevante fazer uma comparação da redação dos casos de teste analisando o nível de detalhe nas instruções fornecidas. Nas tabelas 3, 4, 5, 6 é possível verificar casos referentes à mesma funcionalidade, envolvendo os analistas júnior e sênior, assim como as ferramentas ChatGPT e Bard, respectivamente. Embora os objetivos e resultados esperados tanto dos seres humanos quanto dos modelos de processamento de linguagem natural sejam semelhantes, é perceptível que os seres humanos forneceram mais detalhes nos "passos" a serem seguidos, como "realizar uma pesquisa pelo produto". Isso pode ocorrer devido ao fato de que, no processo de teste (BDD), os seres humanos têm maior liberdade para imaginar como o teste será executado, uma vez que o teste é criado antes do desenvolvimento. Além disso, também é notável que o ChatGPT e o Bard criaram pré-condições que não foram diretamente fornecidas a eles, tais como "o usuário estar logado" ou "o produto estar disponível". Isso se deve ao fato de que eles se baseiam em requisitos semelhantes aos já existentes para a criação dos casos de teste, demonstrando a capacidade desses modelos de aprender e aplicar conhecimento prévio. No entanto, isso também pode levar a alguns erros, como no caso do ChatGPT, que na Tabela 5 cometeu um equívoco no resultado esperado: "O carrinho não está

Tabela 5: Exemplo de Caso de teste gerado pelo ChatGPT

2. Remover um produto do carrinho	
Objetivo: Verificar se é possível remover um produto do carrinho.	
Pré-Condição: Usuário está logado na loja virtual e há pelo menos um produto no carrinho	
Passos	Resultado Esperado
2.1. Acessar o carrinho de compras.	* O produto é removido com sucesso do carrinho. * O carrinho não está vazio após a remoção.
2.2. Localizar o produto no carrinho.	
2.3. Clicar no botão "Remover".	

Tabela 6: Exemplo de Caso de teste gerado pelo Bard

CT-02 - Remover produto do carrinho	
Objetivo: Testar a funcionalidade de remover um produto do carrinho	
Pré-Condição: O produto deve estar no carrinho	
Passos	Resultado Esperado
1. O usuário seleciona o produto que deseja remover do carrinho.	O produto deve ser removido do carrinho
2. O usuário clica no botão "Remover do carrinho".	
3. O produto deve ser removido do carrinho.	

Tabela 7: Exemplo de Caso de Teste do Gabarito

2. Retirar um produto do carrinho	
Objetivo: Validar que é possível remover um produto do carrinho	
Pré-Condição: Possua um produto no carrinho	
Passos	Resultado Esperado
1. Vou para o carrinho	O carrinho fica vazio
2. Seleciono um produto do carrinho	
3. Clico em remover produto do carrinho	
4. O carrinho fica vazio	

Tabela 8: Comparação da geração dos casos de teste

	Quantidade Casos de teste	Cobre todos os cenários?	Valida todas as regras do requisito?	Tempo gasto na criação
Gabarito	9	Sim	Sim	-
Analista Júnior	6	Não	Não	1 hora
Analista Sênior	6	Não	Sim	30 minutos
Bard	5	Não	Não	< 1 min
ChatGPT	5	Não	Sim	< 1min

vazio após a remoção". Nesse caso, o ChatGPT considerou como pré-condição que o carrinho tivesse mais de um produto, embora na descrição da pré-condição do caso de teste ele considerasse que poderia haver um ou mais produtos.

Portanto, podemos concluir que o ChatGPT demonstrou não apenas eficácia na criação de casos de teste, mas também um grande potencial como ferramenta educacional para profissionais de garantia de qualidade. Esse potencial educativo é evidenciado pelos seguintes pontos:

- **Cobertura Abrangente:** Apesar de um menor número de casos, o ChatGPT conseguiu abranger todas as regras do requisito, ao contrário do Analista Júnior. Estudar esses casos de teste ajuda os analistas de testes juniores a entender

como criar testes que cobrem todos os cenários possíveis, aumentando sua capacidade de identificar e abordar lacunas em seus próprios testes.

- **Estruturação Clara:** Os modelos de IA, como o ChatGPT, seguem padrões estabelecidos (como a ISO 29119-3) de maneira consistente, criando casos de teste com pré-condições, passos, objetivos e resultados esperados bem definidos. Isso oferece aos analistas de testes juniores uma referência clara de como estruturar seus próprios casos de teste.
- **Aprendizado de Contexto e Detalhes:** Os analistas de testes juniores podem comparar seus próprios casos de teste com os gerados pela IA, aprendendo como adicionar detalhes importantes e pré-condições relevantes, como "o usuário

estar logado" ou "o produto estar disponível", que podem não ser imediatamente óbvios para iniciantes.

Para os analistas de testes seniores, o ChatGPT pode agilizar a geração de casos de teste, permitindo que dediquem mais tempo à análise de cenários complexos e à cobertura extensiva de testes. Desta forma, o uso combinado de IA e a experiência humana maximiza a eficácia e eficiência no processo de garantia de qualidade.

Assim, para confirmar tais resultados, foi realizada uma última experiência onde os analistas de testes, de diferentes níveis de experiência, ficaram uma semana utilizando o ChatGPT para auxiliar na criação de seus casos de teste. O objetivo desta fase final foi avaliar o impacto educativo da integração da IA no processo de criação de testes, comparando como os analistas aprendem e aprimoram suas habilidades com o auxílio da IA em relação aos métodos tradicionais.

Durante esse período, os analistas de teste foram orientados a usar o ChatGPT para gerar sugestões e *insights* sobre possíveis cenários de teste que talvez não tivessem considerado inicialmente. Ao final da semana, cada analista avaliou o impacto do uso da IA em seu aprendizado, respondendo a perguntas sobre a eficácia da ferramenta na identificação de novos cenários de teste e na descoberta de casos críticos desconhecidos anteriormente. Eles também refletiram sobre como a IA contribuiu para seu desenvolvimento profissional e para a ampliação de suas habilidades de análise de teste.

Os resultados demonstraram que o uso do ChatGPT foi especialmente benéfico para o Analista Júnior, auxiliando-o na identificação de cenários de teste mais abrangentes e proporcionando uma cobertura mais completa e de maior qualidade. A ferramenta de IA ofereceu novas perspectivas e abordagens para a criação de casos de teste, aprimorando seu pensamento crítico e expandindo seu conhecimento sobre possíveis falhas e pontos críticos no sistema. Na criação de novos casos de teste, o Analista Júnior pôde utilizar sua experiência adquirida com a IA para entender melhor quais cenários deveriam ser desenvolvidos.

Para o Analista Sênior, a IA facilitou a criação de casos de teste de forma mais rápida, embora não tenha gerado cenários diferentes dos que ele já havia imaginado. Mesmo assim, a ferramenta permitiu um ganho de tempo significativo no processo de criação dos casos de teste.

Ambos os analistas de testes relataram melhorias na comunicação escrita, tendo em vista que o ChatGPT tende a escrever de uma forma mais clara o que ajudou no processo de melhoria de escrita dos analistas e sua organização em seus processos de trabalho.

Essa experiência final destacou como a IA pode atuar como um recurso educativo eficaz para aqueles com menor experiência, promovendo um ambiente de aprendizado que capacita os analistas de testes a desenvolver novas experiências e a se adaptar a desafios complexos. A utilização da IA no processo de criação de testes contribui para uma melhoria contínua no conhecimento e na prática dos analistas, destacando seu potencial para enriquecer a educação e o desenvolvimento profissional na área de teste de software.

6 Considerações Finais

Neste artigo, apresentamos casos de teste desenvolvidos por dois profissionais de testes com experiências distintas e comparamos esses casos aos gerados por duas ferramentas: ChatGPT e Bard.

Nosso objetivo foi avaliar o uso dessas ferramentas no aprendizado para criar casos de teste de aceitação. Com base em nossa experiência, concluímos que é, de fato, possível utilizar o ChatGPT para o aprendizado por pessoas menos experientes na área. No entanto, é importante ressaltar que com a constante evolução desses modelos, é provável que tanto o ChatGPT quanto o Bard se tornem ainda mais proficientes na cobertura de casos de teste no futuro, permitindo assim ajudar até mesmo aqueles mais experientes.

A experiência com os estudantes de testes destacou várias lições valiosas que podem ser aplicadas no contexto educacional. Primeiramente, a utilização de IA ajudou a melhorar a precisão na identificação de cenários de teste, uma habilidade crucial para estudantes que aspiram a trabalhar com qualidade de software. A exposição a novas abordagens e perspectivas fornecidas pela IA aprimorou o pensamento crítico, permitindo que os profissionais avaliassem e desenvolvessem casos de teste mais robustos. Além disso, a necessidade de documentar e comunicar claramente os cenários de teste e os resultados ajudou a aprimorar a comunicação escrita. O uso sistemático de ferramentas de IA para criar e gerenciar casos de teste promoveu melhores práticas organizacionais, e a capacidade de se adaptar às novas tecnologias e integrar essas ferramentas no fluxo de trabalho foi fundamental para o sucesso dos profissionais de testes.

Com base nesses *insights*, propomos a seguinte metodologia para aplicar uma abordagem semelhante no contexto educacional. Primeiramente, solicitar que os estudantes desenvolvam seus próprios casos de teste e, em seguida, utilizem o ChatGPT e o Bard para gerar casos adicionais. Em seguida, pedir que comparem os resultados, identificando pontos fortes e fracos de cada abordagem. Além disso, incentivar os estudantes a classificar os conjuntos de casos de teste criados por eles mesmos e pela IA, com base em critérios de abrangência, relevância e eficácia. Promover discussões em grupo onde os estudantes possam apresentar suas análises sobre os diferentes conjuntos de casos de teste, aprimorando suas habilidades de comunicação escrita e oral. Estimular os estudantes a iterar sobre seus casos de teste, utilizando o *feedback* das ferramentas de IA e dos colegas para melhorar continuamente a qualidade e a cobertura dos testes.

Essa estratégia pode desenvolver várias competências e habilidades necessárias para quem trabalha com qualidade de software. Ao comparar seus próprios casos de teste com os gerados pela IA, os estudantes aprenderão a identificar lacunas e aprimorar a precisão, melhorando a atenção aos detalhes. A análise crítica dos diferentes conjuntos de casos de teste fomentará o desenvolvimento do pensamento crítico. A necessidade de documentar e discutir seus resultados ajudará a melhorar a comunicação escrita e oral. A prática de criar, gerenciar e refinar casos de teste promoverá melhores habilidades organizacionais. A integração de ferramentas de IA no processo de aprendizado ajudará os estudantes a se adaptarem rapidamente a novas tecnologias e metodologias.

Além disso, é possível utilizar essas abordagens em sala de aula, onde professores podem apresentar exemplos de requisitos ou até mesmo solicitar que as IAs gerem alguns deles. Em seguida, podem mostrar exemplos de casos de teste criados pelas IAs e pedir aos alunos que, de forma colaborativa com as ferramentas, gerem seus próprios casos de teste. Após isso, os resultados podem ser analisados de maneira crítica, avaliando a organização, a cobertura

dos cenários, e identificando possíveis erros das IAs em relação às regras dos requisitos. Dessa forma, os alunos desenvolvem uma visão mais crítica e refinada ao criar seus próprios casos de teste.

Implementar essa metodologia em contextos educacionais pode não apenas melhorar a formação de futuros profissionais de testes, mas também preparar os estudantes para enfrentar os desafios e se adaptar às constantes evoluções no campo da qualidade de software. A utilização de ferramentas de IA como ChatGPT e Bard pode ser uma estratégia eficaz para desenvolver as habilidades essenciais de analistas de testes de forma mais eficiente e abrangente.

Ao concluir este estudo, é importante reconhecer as limitações e ameaças à validade que influenciam os resultados. Primeiramente, a quantidade limitada de participantes (dois QAs com níveis de experiência distintos) restringe a generalização dos resultados. A pequena amostra dificulta a análise de variações mais amplas de performance entre profissionais com diferentes níveis de habilidade e, por isso, não se pode afirmar com segurança que os resultados observados se aplicariam a um grupo maior ou a diferentes contextos.

Além disso, o uso de apenas duas ferramentas de IA, ChatGPT e Bard, também é uma limitação significativa. A escolha dessas ferramentas foi feita com base na acessibilidade e popularidade, mas existem outras IAs que poderiam produzir resultados variados. Uma análise mais aprofundada e diversificada, considerando diferentes modelos, poderia fornecer uma visão mais abrangente sobre as capacidades da IA na criação de casos de teste. Ademais, a estratégia de *prompts* utilizada neste estudo foi limitada, e uma discussão mais detalhada sobre variações de *prompts* e abordagens para geração de casos de teste não foi amplamente explorada. Isso abre uma margem considerável para melhorias futuras.

Por fim, por ser um estudo preliminar e exploratório, os resultados devem ser interpretados com cautela. A rápida evolução dos modelos de IA pode tornar os achados deste estudo desatualizados em um futuro próximo, e a falta de uma maior discussão sobre outras estratégias de testes e *prompts* também sugere que os resultados podem ser diferentes em cenários mais variados. Dessa forma, estudos futuros com mais participantes, diferentes ferramentas e abordagens de geração de casos de teste são necessários para validar e expandir os achados apresentados.

Um futuro avanço nessa pesquisa, seria explorar a eficácia dessas ferramentas em um grupo mais amplo de participantes e em contextos variados. Isso permitiria uma compreensão mais abrangente de como as ferramentas de IA podem impactar o aprendizado e o desenvolvimento contínuo dos analistas de teste. Expansões nesse sentido possibilitariam uma análise mais robusta sobre a aplicabilidade e os desafios do uso de IA no aprendizado e prática de testes de software, garantindo maior relevância e representatividade dos resultados obtidos.

Referências

- [1] Brazilian Software Testing Qualifications Board. 2023. *Syllabus*. https://bcr.bstqb.org.br/docs/syllabus_ctfl_4.0br.pdf
- [2] FIA BUSINESS SCHOOL. 2023. O que é Bard e como usar a inteligência artificial do Google? <https://fia.com.br/blog/bard/>. Acesso em 27 de março de 2023.
- [3] FIA BUSINESS SCHOOL. 2023. O que é Chat GPT, impactos e como usar esta inteligência artificial? <https://fia.com.br/blog/chat-gpt/>. Acesso em 30 de março de 2023.
- [4] Leonardo de Oliveira Figueiredo, Aparecida Maria Zem Lopes, Valeria Cristiane Validorio, and Simone Cristina Mussio. 2023. Desafios e impactos do uso da Inteligência Artificial na educação. *Educação Online* 18, 44 (nov. 2023), e18234408. <https://doi.org/10.36556/eol.v18i44.1506>
- [5] Google. 2023. Bard. <https://bard.google.com>. Acesso em 25 de setembro de 2023.
- [6] H. Hourani, A. Hammad, and M. Lafi. 2019. The Impact of Artificial Intelligence on Software Testing. In *2019 IEEE Jordan International Joint Conference on Electrical Engineering and Information Technology (JEEIT)*. IEEE, 565–570.
- [7] ISO/IEC/IEEE. 2021. ISO/IEC/IEEE 29119-3:2021. <https://www.iso.org/standard/79429.html>. Acesso em 2 de outubro de 2023.
- [8] T. Li et al. 2023. Nuances are the Key: Unlocking ChatGPT to Find Failure-Inducing Tests with Differential Prompting. In *Proceedings of the 45th ACM/IEEE International Conference on Software Engineering (ASE 2023)*. Association for Computing Machinery, 60–71.
- [9] OpenAI. 2022. ChatGPT. <https://openai.com/blog/chatgpt/>. Acesso em 25 de setembro de 2023.
- [10] Roger S. Pressman. 2016. *Engenharia de Software* (8ª ed.). McGraw-Hill.
- [11] K. Ramos da Silva et al. 2023. Inteligência Artificial e Seus Impactos na Educação: Uma Revisão Sistemática. *RECIMA21 - Revista Científica Multidisciplinar* (nov 2023), 17. <https://doi.org/10.47820/recima21.v4i11.4353>
- [12] John Ferguson Smart. 2023. *BDD in Action, Second Edition: Behavior-Driven Development for the Whole Software Lifecycle* (2ª ed.). Manning Publications.
- [13] Ian Sommerville. 2011. *Engenharia de Software* (9ª ed.). Pearson Prentice Hall. p. 5.
- [14] A. Talasbek. 2023. *ARTIFICIAL AI IN TEST AUTOMATION: SOFTWARE TESTING OPPORTUNITIES WITH OPENAI TECHNOLOGY-CHATGPT*. Master's thesis. Suleyman Demirel University.
- [15] Pedro Henrique Dias Valle, Ricardo Ferreira Vilela, Guilherme Guerino, and Williamson Silva. 2023. Soft and Hard Skills of Software Testing Professionals: A Comprehensive Survey. *SBQS'23* (November 07–10 2023), 10. <https://doi.org/10.1145/3629479.3629509>
- [16] Z. Xie et al. 2023. ChatUniTest: a ChatGPT-based automated unit test generation tool. *arXiv* (May 8 2023).